导师汇报：前处理与大模型推理

截至097。**全部为raw标签，不含后处理。各表内同ID比较，跨表不作差；均为已有研究暴露的开发材料。** PA＝正确率；错误支持＝真实非S却预测S。

一、与原VeriFact的差异

模块	原VeriFact较强发布配置	本项目
前处理	100条句子事实；BGE-M3稠密＋学习稀疏检索、融合、重排	段落证据；稠密＋BM25，C48候选，再选最多16段、约8000字符
Judge	R1-70B；reasoning分支输出标签与简洁理由	V4 T-S：thinking-high，输出标签、理由、checks及三分数
教学示例	reasoning分支无示例；非reasoning有合成示例	F4：固定4个其他患者的医生标注示例，2S/1NS/1NA

N-S＝非thinking评分；T-S＝thinking-high评分。C48是候选数，不是模型实际读取段数。源码依据

1.1 前处理流程

系统	从claim到Judge实际输入
原VeriFact较强发布配置	atomic claim → 同患者、目标住院范围的句子事实 → BGE-M3稠密＋学习稀疏召回与融合 → 去重、BGE重排、top100 → 按时间组织reference
本项目C48	原claim → 同患者、住院日期内的原文段落切片 → 稠密与BM25分别排序 → 交替保留48个不重复候选 → BGE重排 → 按约束选最多16段、约8000字符 → 按时间组织reference

1.2 前处理具体差异

环节	原VeriFact发布配置／作者代码	本项目实际实现	差异性质
核验目标与query	以atomic claim作为检索query	使用同一原claim，不改写目标、 不加入目标出院总结上下文	共同设置，非新增方法
患者与时间范围	本对照为current admission； 按患者和住院起止日过滤	按同患者、 CHARTDATE落在入院至出院日期内筛选， 排除出院总结	患者／日期过滤非新意； 本项目实际用日期过滤， 不是逐条HADM_ID硬匹配
源证据单位	本对照为sentence facts； 原论文另比较过atomic源事实	直接从原始note取段落切片， 不用LLM重写片段	句子级改为段落切片级； 可能保留相邻描述， 也可能增加无关文字
长文本切分	上述发布配置以句子为源事实单位	先按空行分段；超过640字符时， 在后半段空白处继续切分， 保存原文起止位置	不是语义事件切分， 不保证限定词、 列表标题或跨段关系完整
稠密召回	BGE-M3 dense	同模型家族的dense表示， 按原claim计算相关性	模型家族相近； 不能仅凭模型名认定输入／ API数值等价
另一条召回路线	BGE-M3 learned sparse： 模型生成token权重	本地BM25：词面匹配、词频和逆文档频率	BM25不是原作者的学习稀疏表示
候选合并	作者维护代码默认distribution-based score fusion， 由向量库融合两路结果	各路先取前80；dense、 BM25交替加入未重复ID，满48停止； 候选足够时保留各路前24	C48用名额保留，非原作者融合， 也非本项目A48的RRF

环节	原VeriFact发布配置／作者代码	本项目实际实现	差异性质
相关性重排	配置启用BGE rerank， 之后限制topN；本对照最终100条	用原claim对48候选的检索文本做BGE rerank；检索文本含日期、类别、 描述和正文	两边都有重排； 重排分数是相关性， 不是临床支持概率
同一note的容量	所核对topN链路没有本项目 “每note最多2段”规则	按重排分数降序贪心选段， 每note最多2段，总计最多16段	控制来源集中， 也可能排除同note的关键第三段
去重口径	按TEXT精确重复去重	选段时仅对“日期＋类别＋正文” 相同的片段去重	本项目允许跨日期重复正文保留； 不等于识别重复临床事件
最终长度控制	按top100句子事实控制条数， 不套本项目8000字符打包规则	逐段信息头和正文计入8000字符预算； 放不下则跳过，不对已选切片再次裁尾； 全局住院头另计	实际reference可略超8000字符； 两系统并非等信息量比较
展示顺序	absolute_time：按时间排列， 附入出院时间、日期、类别及描述	选段按相关性，入模前再按日期、时间、 note和原文位置排列	时序展示并非本项目首创
输入中的来源定位	所核对absolute_time文本显示日期、 时间、类别和DESCRIPTION； 内部另有节点元数据	展示日期、时间、类别、Note ID和原文字符区间，并保存SHA； 基础formatter不展示DESCRIPTION， 但检索文本保留它	定位更细； DESCRIPTION没有直接给Judge， 可能丢失检查名称等线索。 不能说原系统没有内部溯源

原系统列以发布 `rater-121` 实参为主；融合及格式细节依据归档作者代码 `f115d36` ，不反推论文每次运行均完全相同。发布配置核查 · 作者检索与格式代码 · 融合核查 · 本项目检索代码 · 切分与打包代码

1.3 哪些差异已有实验证据

研究点	已有证据	可汇报的范围
输入压缩	078桥接：C48平均约8056字符，发布reference约22474字符； Judge均费约¥0.02592／¥0.03819	字符约少64%，Judge费用约少32%； 未证明精度等效
证据相关性与临床效用	010同Judge时C48多对15条；后续thinking桥接少对5条	检索更相关、包更紧凑不保证核验更准； 结果见第三、第五节
段落完整性	097回查482条证据：405条未覆盖完整父段，77条覆盖完整父段	当前切片仍可能破坏上下文； 源文依赖方法尚无分类成绩

来源：078 · 097源段核查。**当前前处理成果是紧凑、可回查的证据管线及受控比较，尚未证明通用精度提升。**

二、最大历史覆盖：1333条／30人

1374个去重ID → 排除示例患者涉及的32条 → 排除9条无有效raw → **1333条**。含自然、类别富集及压力材料，仅作描述性汇总。

配置	MCC	PA	正确数	错误支持数
原VeriFact发布预测	0.4754	78.39%	1045/1333	113
C48＋V4 T-S＋F4	0.5402	76.44%	1019/1333	28

正确数−26，MCC＋0.0648，错误支持−85。 覆盖与复核台账

三、按顺序加入组件的消融

缺少“仅换C48、保留原作者原生Judge”的实验臂；以下以**发布证据＋V4 N-S**为基线。

3.1 固定V4：换C48 → 开thinking → 加F4

078成套设计192条 → 排除示例患者16条、任一臂无效10条 → **166条／22人**。

累计配置	MCC	PA	正确数	错误支持数	较上一步净正确
原VeriFact发布预测（背景参照）	0.5506	84.34%	140/166	9	—
基线：发布reference＋V4 N-S	0.5937	81.93%	136/166	2	—
① C48＋V4 N-S	0.4928	77.11%	128/166	3	−8
② C48＋V4 T-S	0.5107	75.90%	126/166	1	−2
③ C48＋V4 T-S＋F4	0.5630	78.92%	131/166	1	＋5

3.2 固定C48：开thinking → 加F4

078成套设计384条 → 排除示例患者32条、任一臂无效12条 → **340条／22人**。

累计配置	MCC	PA	正确数	错误支持数	较上一步净正确
原VeriFact发布预测（背景参照）	0.4812	81.18%	276/340	18	—
C48＋V4 N-S	0.4028	72.65%	247/340	12	—
C48＋V4 T-S	0.4883	75.29%	256/340	6	＋9
C48＋V4 T-S＋F4	0.5200	76.76%	261/340	4	＋5

两表均从078已有回执重建，核对了模型、claim和C48 reference；不是完整八臂交互实验。N-S/T-S输出预算分别为2048/8192。完整指标与区间

四、固定四例F4：不同队列的表现

队列	配置	MCC	PA	正确数	错误支持数
073确认，60条／10人	原VeriFact	0.3669	70.00%	42/60	9
	C48＋V4 T-S，无示例	0.6193	76.67%	46/60	0
	C48＋V4 T-S＋F4	0.6348	78.33%	47/60	0
075筛查，36条／6人	原VeriFact	0.2030	61.11%	22/36	6
	C48＋V4 T-S＋F4	0.5246	72.22%	26/36	0
084／085共同177条／21人	原VeriFact	0.5774	87.01%	154/177	8
	C48＋V4 T-S，无示例	0.4782	75.71%	134/177	4
	C48＋V4 T-S＋F4	0.5260	78.53%	139/177	3
092历史共同935条／24人	原VeriFact	0.4836	79.25%	741/935	68
	C48＋V4 T-S，无示例	0.4898	73.16%	684/935	22
	C48＋V4 T-S＋F4	0.5083	74.97%	701/935	19

相对原作者	ΔPA	ΔMCC及患者95%区间
073 F4	＋8.33个百分点	＋0.2679 [＋0.0692, ＋0.4750]
075 F4	＋11.11个百分点	＋0.3216 [＋0.0223, ＋0.6237]

073/075的ΔPA区间仍跨0；队列有历史重叠。935条是旧B/F4共同有效集，不能当成1333条之外的新样本。073 · 084 · 085 · 零API复核

示例机制与选择对照

实验	N	各臂正确数
071标签对应	93	无示例70／正确四例73／错配标签71
072动态选择确认	58	无示例39／固定四例41／动态四例41
078固定四例	125	无示例85／四例88
082扩覆盖	178	无示例129／四例134
087示例证据对应	105	无示例81／完整四例84／去证据82／错配证据80

来源：071 · 072 · 078 · 082预测 · 087

五、前处理：开发与后续结果

实验	N	结果	结论
009候选检索	650	融合／纯dense／C48正确506／487／509	C48较融合净＋3
010同Judge证据比较	650	发布reference／C48正确511／526；原作者555	该轮C48净＋15
078／096 thinking桥接	184	发布reference／C48正确144／139	后续C48净−5
078输入与费用	桥接队列	C48字符约为发布包36%；Judge费用约低32%	输入节省，未证明精度等效
068包效用诊断	236	原包／修正版正确177／181，MCC .5058／.5238，错误支持均3	4个救回中3个同病例重复；增删混合

来源：009 · 010 · 078 · 096 · 068。不同队列、推理模式间的差值不算同条件复现。

六、后续推理候选

6.1 090示例压缩：自然共同174条

配置（本项目均为C48＋V4 T-S）	MCC	PA	正确数	错误支持数
原VeriFact发布预测（背景参照）	0.4256	79.31%	138/174	10
无示例	0.3594	68.97%	120/174	7
完整四例F4	0.3643	71.84%	125/174	6
信息覆盖压缩四例P90	0.4521	75.86%	132/174	5
普通抽取四例Q90	0.3996	72.41%	126/174	5

P90较F4：净＋7，ΔMCC＋0.0879 [＋0.0118, ＋0.1656]，费用约−22%。压力65条无示例/F4/P/Q正确40/38/39/40；自然NS召回F4/P为0%/15.38%。P/Q并非等token预算。090

6.2 097简洁判断：共同158条

配置	MCC	PA	正确数	错误支持数
原VeriFact发布预测	0.5228	81.01%	128/158	7
C48＋V4 T-S复杂评分，无示例	0.5057	73.42%	116/158	1
C48＋V4简洁判断，无示例	0.5625	79.11%	125/158	2

配置	MCC	PA	正确数	错误支持数
发布reference＋V4复杂评分	0.4949	76.58%	121/158	2
发布reference＋V4简洁判断	0.5367	79.11%	125/158	3

C48下简洁净＋9；发布reference下同期净＋4。12条同输入重复中4条raw改变；C48复杂评分来自历史缓存，尚未证明稳定收益。097

七、汇报结论

模块	已支持的结论	尚未支持
C48	输入和费用降低	稳定精度优势
T-S	部分队列降低错误支持、改善MCC	稳定准确率提升
F4	对本项目基线常有小增量；小队列可优于原作者	大范围准确率领先
组合	可改善本项目基线	整体稳定超过原VeriFact；组件效应可直接相加

完整类别指标、混淆矩阵、患者区间及来源SHA见复核台账和任务索引。